

김앤(세미수)정

TEAM4

5가지 대화 유형 Class를 분류하는 딥러닝 모델

DATA_EDA

DKTC 훈련 데이터

tunib-ai/DKTC



	idx	class	conversation
0	0	협박 대화	지금 너 스스로를 죽여달라고 애원하는 것인가?\n아닙니다. 죄송합니다.\n죽을 ...
1	1	협박 대화	길동경찰서입니다.\n9시 40분 마트에 폭발물을 설치할거다.\n네?\n똑바로 들어 ...
2	2	기타 괴롭힘 대화	너 되게 귀여운거 알지? 나보다 작은 남자는 쳤봤어.\n그만해. 니들 놀리는거 재미...
3	3	갈취 대화	어이 거기\n예??\n너 말이야 너. 이리 오라고\n무슨 일.\n너 옷 좋아보인다?...
4	4	갈취 대화	저기요 혹시 날이 너무 뜨겁잖아요? 저희 회사에서 이 선크림 파는데 한 번 손등에 ...

Basic Information

클래스	Class No.	# Training	# Test
협박	00	896	100
갈취	01	981	100
직장 내 괴롭힘	02	979	100
기타 괴롭힘	03	1,094	100
일반	04	-	100

데이터 분석

1. 데이터 성격

여러 사람의 대화

- 발화자가 바뀔 때마다 줄바꿈(\n) 기호로 구분
- 음성 데이터 기반 (노이즈 존재)



2. 데이터 분포

협박: 896 / 갈취: 981 / 직장 내 괴롭힘: 979 / 기타 괴롭힘: 1094
길이가 150~300 내에 대부분 포함

3. 데이터 특징

- 비속어 포함 비율: 21.72%
- 문맥 파악이 핵심 (화자들의 관계)
 - 존칭을 쓰면서 정중한 위협을 가하는 경우
 - 두 화자 모두 비속어를 사용하는 경우 존재
 - 직장 내 괴롭힘의 경우 권력 관계가 뚜렷한 성향

--- [Class Distribution] ---
Other Abuse : 1094 (27.70%)
Extortion : 981 (24.84%)
Workplace Abuse : 979 (24.78%)
Threat : 896 (22.68%)



데이터 수집: 일반대화 합성 데이터

Claude, Gemini

일반대화 데이터 수집 : 합성 데이터 프롬프트

당신은 실제 사람들의 음성 대화 녹취록을 텍스트로 변환하는 전문가입니다.
자연스러운 '**'일반 대화'**' 텍스트를 **한 번에 50개** 생성해주세요.
단, 아래의 [포맷 및 스타일 조건]을 반드시 엄격하게 지켜야 합니다.

[포맷 및 스타일 조건]

- 화자 구분: 화자가 바뀔 때마다 줄바꿈(₩n)으로 구분합니다.
"A:", "B:", "선생님:" 같은 지시어나 라벨을 절대 텍스트에 포함하지 말고, 오직 대화 내용만 출력해야 합니다.
- 음성 기반 노이즈: 실제 말하는 것처럼 문어체를 지양합니다.
 - "음", "그치" 등 추임새를 섞고, 띄어쓰기 오류를 허용합니다.
 - 소리 나는 대로 적힌 약간의 오타나 줄임말 ("해알까봐")도 1~2개 정도 포함합니다.
 - ', , ! ?' 특수기호를 포함합니다.
- 길이 및 개수 조건 (총 50개):
 - 40개: 공백 포함 약 [150~300자] 내외
 - 7개: 공백 포함 약 [300~500자] 내외
 - 3개: 공백 포함 약 [600~800자] 내외

[출력 형식]

나중에 데이터를 분리할 수 있도록, 각각의 대화(1~50번) 사이에 반드시 `=====` (구분선)을 넣어주세요.
다른 부가 설명(인사말 등) 없이 오직 생성된 대화 텍스트만 출력합니다.

1. 포맷

화자 구분: 화자가 바뀔 때마다 줄바꿈으로 구분
음성 기반 노이즈 포함
길이 및 개수 조건 (50개 기준)

2. 50개씩 반복

동일한 포맷과 길이 비율 조건을 유지하면서, 내용과 대화
흐름이 완전히 다른 새로운 '일반 대화' 50개를 추가로 생성

3. Hard Negative

모델이 '대리님' 같은 직급이나 거친 단어 등 특정 트리거
단어에 낚여 일반 대화를 오분류하는 것을 방지

데이터 전처리

데이터 전처리

- 필요없는 컬럼 삭제 (idx)
- 중복 데이터 확인 후 제거
- \n 줄바꿈 문자 공백 처리
 - 테스트 데이터의 예시를 보면 \n 문자열도 없음
 - 화자변경을 모델이 명시적인 기호 없이 텍스트의 흐름과 문맥으로 파악해야함
- 의미 없는 특수 기호 제거 (정규표현식 사용)
- 특수 기호 띄어쓰기 적용
- 다중 공백 하나로 압축
- 베이스라인 모델 실험 이후에 더 생각해볼 부분
 - 테스트 데이터 예시를 보면 구두점 등 특수 기호가 아예 없는데 이게 모든 테스트 데이터가 그런건지 불확실함
 - augmentation 진행할 때에 특수 기호 삭제하는 경우도 넣으면 좋을듯



```
def standard_preprocess(text):
    if not isinstance(text, str):
        return ""
    # 공백 정규화
    text = re.sub(r'\s+', ' ', text)
    # URL 및 이메일 제거
    text = re.sub(r'http\S+|www\S+|mailto:\S+', '', text)
    # 한글, 숫자, 영문, 자음/모음, 기본 문장부호만 남기기
    text = re.sub(r'^가-힣0-9a-zA-Zㄱ-ㅎㅏ-ㅣ\s.?![,]', '', text)
    return text.strip()
```

```
# 4. 클래스 라벨 맵핑 (모든 케이스 대응)
label_dict = {
    '협박 대화': 0, '협박': 0, '협박대화': 0,
    '갈취 대화': 1, '갈취': 1, '갈취대화': 1,
    '직장 내 괴롭힘 대화': 2, '직장내괴롭힘': 2, '직장내괴롭힘대화': 2,
    '기타 괴롭힘 대화': 3, '기타괴롭힘': 3, '기타괴롭힘대화': 3,
    '일반 대화': 4, '일반': 4, '일반대화': 4
}

# label 컬럼 생성
if 'class' in train_data.columns:
    train_data['label'] = train_data['class'].map(label_dict)
else:
    print("'class' 컬럼을 찾을 수 없습니다!")
```

```
# 5. 중복 및 결측치 제거
# 정제된 텍스트('conversation')를 기준으로 중복 제거
train_data = train_data.drop_duplicates(subset=['conversation']).dropna(subset=['label'])

# 6. 불필요한 컬럼 삭제 및 정리
if 'idx' in train_data.columns:
    train_data.drop(['idx'], axis=1, inplace=True)
```

데이터 선정 실험: Baseline

KLUE-RoBERTa (Large)

 **klue/roberta-large** 

 like 63  Follow  KLUE Benchmark 72

 Fill-Mask  Transformers  PyTorch  Safetensors  Korean roberta korean klue  arxiv:2105.09680

이유: 현재 한국어 NLP 작업에서 가장 '정석'이자 성능이 검증된 모델

학습 세팅

MAX_LENGTH	BATCH_SIZE	LEARNING_RATE	EPOCHS	SEED
256	16	2 e-5	3	42

데이터 선정 실험: Baseline

KLUE-RoBERTa (Large)

test sentences: two-way conversation

submission score: 0.70

=====

 확신도가 포함된 테스트 문장 예측 결과

=====

문장: 너 어제 내가 말한 거 왜 처리 안 했어? 죄송해요 진짜 어제 몸이 너무 안 좋아서 그랬어요.

결과: 협박 대화 (확신도: 99.97%)

문장: 야 이번에 부모님한테 용돈 받았대며? 응 근데 이건 진짜 학원비 내야 하는 돈이라서 안 돼.

결과: 갈취 대화 (확신도: 99.67%)

문장: 이대리 이 기획안 제정신으로 쓴 거야? 초등학생도 이것보다는 잘 쓰겠다. 죄송합니다 다시 각

결과: 직장 내 괴롭힘 대화 (확신도: 99.98%)

문장: 야 재 또 저 똥 입고 왔네? 진짜 냄새나게 생겼다. 야 들리겠어 그만해. 들으라고 하는 소리C

결과: 기타 괴롭힘 대화 (확신도: 99.97%)

문장: 팀장님 오늘 회의록 정리해서 메일로 보내드렸습니다. 아 방금 확인했습니다 고생 많으셨어요

결과: 일반 대화 (확신도: 94.76%)

MODEL

모델 선정

모델 선정 및 채택 로직

협박, 갈취, 직장 내 괴롭힘, 기타 괴롭힘, 일반 대화 5가지 대화 유형 Class를 분류

모델 후보

우선순위	모델명	특징 및 강점	데이터 활용 포인트 (이유)
1위	KcELECTRA	온라인 커뮤니티, 댓글 등 낱것의 구어체로 학습됨. 비속어, <u>오탈자</u> , 신조어 판별 최강.	<u>엣지</u> 케이스(죽겠다, 미치겠다 등)가 쓰이는 현실적인 대화 맥락을 가장 잘 이해함.
2위	DeBERTa-v3	단어의 위치와 의미를 분리해서 계산. 문맥 파악 능력이 현재 NLP 모델 중 최상위권.	"죽겠다"라는 단어가 문장의 앞/뒤 어디에 <u>오느냐</u> 에 따라 공격/일반을 가려내는 <u>정밀도가</u> 매우 높음.
3위	RoBERTa-Large (KLUE)	가장 안정적인 성능. 한국어 표준 문법과 문장 간의 관계 파악에 최적화됨.	5개 <u>클래스</u> 간의 모호한 경계를 허물지 않고 안정적으로 분류해주는 든든한 베이스 모델임.

하이퍼파라미터 (1차)

MAX_LENGTH	BATCH_SIZE	LEARNING_RATE	OPTIMIZER	SCHEDULER	EPOCHS	Weight Decay	Epsilon	Max Grad Norm	SEED
128	32	1 e-5	AdamW	Linear Warmup	5	0.01	1 e-5	1	42

모델 선정 및 채택 로직

model	특징	Loss	Acc	F1 score	Submission	최종 선택
KcELECTRA	구어체, 신조어, 오탈자가 많은 한국어 댓글 데이터 학습에 특화되어 실제 온라인 대화 분석에 강한 모델	0.2819	92.55 %	0.9220	0.77	O
DeBERTa-v3	단어의 의미와 상대적 위치를 분리해서 학습하는 기술(Disentangled Attention)로 문맥 이해도를 극적으로 높인 모델	0.9401	82.7%	0.83	0.60	
KLUE-RoBERTa (Large)	대한 한국어 벤치마크(KLUE) 데이터로 세밀하게 학습되어, 한국어 태스크 전반에서 가장 안정적이고 뛰어난 베이스라인 성능을 보여주는 모델	1.6605	92.51%	0.92	0.69	





IMPROVEMENT

성능향상을 위한 노력

현재 모델의 약점 및 원인 분석: 오답노트

DATA

	문장	정답	예측	확신도(%)
1	랑 계속 만나는 게 좋을거야?	갈취(1)	협박(0)	88.66
2	안튀가만히 안두면 어쩔텐데	기타괴롭힘(3)	협박(0)	88.43
3	났았어 얼른 넣어 잔말말고 네.	갈취(1)	협박(0)	88.41
4	비입니다. 제발 돌려주십시오	갈취(1)	협박(0)	87.98
5	상시도 제정신이 아니었지만.	협박(0)	기타괴롭힘(3)	87.77
6	어. 입만 열면 구라지 이새끼는	협박(0)	갈취(1)	86.93
7	나봐. 재수가 없으려니까. 하.	직장내괴롭힘(2)	기타괴롭힘(3)	86.89
8	네 여기 있습니다 살려 주세요	협박(0)	갈취(1)	86.76
9	저게 또 고장난거 까지 아네.	직장내괴롭힘(2)	갈취(1)	86.52
10	가 가져갔어 그냥 다 죽자 우리	협박(0)	갈취(1)	85.88
11	다 되갑니다 제발 기다리세요	갈취(1)	협박(0)	85.13
12	같아? 제발.시간을 좀 주세요.	협박(0)	갈취(1)	85.12
13	돈가 내 어찌든 마련해보겠네.	협박(0)	갈취(1)	85.0
14	보내요 바로 보내드린다니까	갈취(1)	직장내괴롭힘(2)	84.75
15	이질 거니까 두고봐 아 알겠어.	갈취(1)	기타괴롭힘(3)	84.71
16	됐고!!빨리 뒷사람 부르라고!!!	갈취(1)	기타괴롭힘(3)	84.58
17	요 아니 그게 무슨 말이에요?	기타괴롭힘(3)	직장내괴롭힘(2)	83.84
18	아.저는 굳이.그렇게 까지.하	직장내괴롭힘(2)	갈취(1)	82.83
19	쌈. 아니. 말보로 레드. 어어.	갈취(1)	기타괴롭힘(3)	82.18
20	갈 집애나 찌꺼려져 있어 그냥	직장내괴롭힘(2)	기타괴롭힘(3)	81.85





협박-갈취-기타괴롭힘 경계 학습 심화

- 협박과 갈취 구분
 - 둘다 [조건(안하면) + 위협]의 문장구조
 - 갈취의 핵심은 물질적 이득
 - **경제적 키워드 변환**
- 기타 괴롭힘
 - 명확한 하위 카테고리 설정
 - **비하형, 가학형, 배제형**



일반 대화 hard negative 증폭

- 트리거 단어 편향 감소
 - **트리거 단어**가 포함된 일반대화의 데이터 증강
- 모델의 변별력(인내심) 강화
 - 공손한 위협 또는 거친 일상 대화 데이터의 증강



오답노트의 틀린 데이터 증강

- **유의어 교체(SR)**
 - 오답 문장 내의 핵심 단어를 유사한 의미로 교체
- **어순 변화(SR)**
 - 오답 문장의 구성을 변화
- **역번역(BT)**
 - 오답 문장을 한-영-한으로 데이터 증강

Augmentation

데이터 증강

증강 실험 종합 결과

KcELECTRA model submission score: 0.77

증강 실험 baseline model : KcELECTRA	주요 목적 및 전략	적용된 증강 기법	검증 지표	Submission	결과 분석
실험 1	클래스 경계 강화 (협박/갈취/기타 구분)	- 경제적 키워드 변환 - 명확한 하위 카테고리 설정	Loss : 0.34 Acc: 88.3% F1: 0.89	0.74	- 클래스 간 핵심 차이를 모델에게 학습시켜 결정 경계를 정교화. - BERT를 통한 문맥 정제로 데이터 품질을 높였으나, 전체 Test 분포를 커버하기 부족했음.
실험 1-1	클래스 경계 강화 (협박/갈취/기타 구분)	맥락에 맞게 바꿔주기 위해서 BERT모델을 도입	Loss : 0.32 Acc: 91.8% F1: 0.89	0.72	
실험 2	과잉 확산 억제 (Hard Negative 증폭)	- 일반 대화 10~15배 증폭 - 타 클래스 2~3배 증폭 보강	Loss : 0.03 Acc: 93.7% F1: 0.92	0.72	증폭 배수를 줄이거나 다른 클래스 증강과 같이 해야 효과가 있을 것으로 예상됨
실험 3	취약 패턴 정복 (오답 노트 문장 증강)	- SR (유의어 교체) - RS (어순 변화) - BT (한-영-한 역번역)	Loss : 0.26 Acc: 93.0% F1: 0.93	0.74	오히려 오답 패턴만 더 학습하다보니 일반화 성능을 높이는데 실패

문제 상황 진단

실험 단계 (step)	baseline model	데이터 구성 및 증강 방식	Submission Score
초기 베이스라인(step 1)	KcELECTRA	basic 일반 대화 합성 데이터	0.74
베이스라인 고도화(step 2)		basic 일반 대화 합성 데이터 + (Hard Negative 100개 + 일반 대화 200개)	0.77
Data Aug 1(step 3)		모델의 취약 클래스 집중 증강	0.74
Data Aug 2(step 4)		Hard Negative 문장 증폭	0.72
Data Aug 3(step 5)		모델이 틀린 문장(오답 패턴) 증폭	0.74



submission score 에 비해 accuaracy가 높게 나옴 → 데이터 누수 문제 예상

문제 상황 진단

Data Leakage 문제 해결 후 3 step 실험 다시 시도

실험 구분	baseline model	상세 내용 (실험 전략)	데이터 분할 (Train/Val)	Submission Score
Data Aug 1(step 3-a)	KcELECTRA	취약 클래스 증강 데이터 재학습 (누수 방지 적용)	80% : 20%(고정)	0.69
Data Aug 1(step 3-b)			80% : 20%(고정)	0.60

발견한 문제점

- 1. 모든 증강 실험 결과를 보면,
 - 로컬 (train/val)의 f1 score, 클래스별 성적은 향상하지만, actual submisssion 점수는 감소하거나 동일한 결과
- 2. Dataset에 Hard Negative 일반 문장이 대부분 1-way

DATA Re-collection

일반대화 합성 데이터 추가수집

적대적 검증 - train vs. test

가설 검증

가설 1. train/val set과 test 데이터의 분포가 아예 다른 상황이다 (괴리가 있다)
가설 2. test의 라벨을 예측할 때에 모델이 못하는 부분은 위협 클래스가 아닌 일반대화 클래스이다.

dataset

basic 일반대화

+

1-way HN

전체 Train vs. Test 결과

=====

🎯 적대적 검증 ROC-AUC Score: 0.5381

=====

일반대화 Train vs. Test 결과

=====

📊 Train(합성 일반) vs Test(5-Fold 예측 일반) AUC: 0.9495

=====

결과:

- 전체 데이터 (4가지 위협 클래스 포함) 로 비교한 결과: **0.5381** → 두 데이터의 분포가 비슷함
- 일반대화 클래스만 비교한 결과 : **0.9495** → 데이터의 분포가 다름

2-way Hard Negative

1-way hard negative 문제점 개선

basic 일반대화

+

1-way HN

+

2-way HN

baseline submission score: 0.77



submission score: 0.78

Epoch	Training Loss	Validation Loss	Accuracy	F1 Macro
1	1.357316	0.955833	0.784810	0.765201
2	0.591878	0.430589	0.911392	0.904223
3	0.391494	0.304509	0.918208	0.912115
4	0.298413	0.264761	0.926972	0.921738
5	0.242866	0.249102	0.928919	0.923835

	precision	recall	f1-score	support
협박 대화	0.88	0.88	0.88	178
갈취 대화	0.91	0.91	0.91	195
직장 내 괴롭힘 대화	0.93	0.96	0.94	194
기타 괴롭힘 대화	0.93	0.87	0.90	202
일반 대화	0.98	1.00	0.99	258
accuracy			0.93	1027
macro avg	0.92	0.92	0.92	1027
weighted avg	0.93	0.93	0.93	1027

=====

 Train(합성 일반) vs Test(예측 일반) AUC: 0.8276

=====

 [합성 데이터에서 유독 튀는/부족한 핵심 키워드 Top 15]

- 위치가 (중요도: 0.0270)
- 원래 (중요도: 0.0157)
- 화가 (중요도: 0.0152)
- 너무 (중요도: 0.0140)
- 그래 (중요도: 0.0139)
- 그니까 (중요도: 0.0121)
- 저기 (중요도: 0.0110)
- 알겠습니다 (중요도: 0.0105)
- 여기서 (중요도: 0.0105)
- 조심히 (중요도: 0.0101)
- 오늘도 (중요도: 0.0097)
- 에버랜드 (중요도: 0.0097)
- 죽겠어 (중요도: 0.0092)
- 채우는 (중요도: 0.0086)
- 보자마자 (중요도: 0.0079)

4가지 위협 클래스 분포(AUC)

- 협박 : 0.5356
- 갈취 : 0.4015
- 직장 내 괴롭힘 : 0.5946
- 기타 괴롭힘 : 0.4678

Other Theme 일반대화

앞 실험의 분포 결과를 기반 추가실험



submission score: 0.78



submission score: 0.81

Epoch	Training Loss	Validation Loss	Accuracy	F1 Macro	
1	1.370545	0.947347	0.789778	0.765064	
2	0.571178	0.429468	0.901639	0.893014	
3	0.387496	0.323505	0.908390	0.900885	
4	0.274013	0.295712	0.906461	0.898986	
5	0.239751	0.286336	0.909354	0.902050	
precision recall f1-score support					
협박 대화		0.88	0.81	0.84	178
갈취 대화		0.85	0.90	0.88	195
직장 내 괴롭힘 대화		0.93	0.94	0.94	194
기타 괴롭힘 대화		0.86	0.87	0.86	202
일반 대화		0.99	0.99	0.99	268
accuracy			0.91	1037	
macro avg		0.90	0.90	0.90	1037
weighted avg		0.91	0.91	0.91	1037

=====

Train(합성 일반) vs Test(예측 일반) AUC: 0.7358

=====

- [합성 데이터에서 유독 튀는/부족한 핵심 키워드 Top 15]
- 안경 (중요도: 0.0180)
 - 기타 (중요도: 0.0154)
 - 원래 (중요도: 0.0138)
 - 위해 (중요도: 0.0129)
 - 나를 (중요도: 0.0093)
 - 그치 (중요도: 0.0092)
 - 사람이 (중요도: 0.0090)
 - 위치가 (중요도: 0.0090)
 - 알았어 (중요도: 0.0087)
 - 오늘 (중요도: 0.0083)
 - 운동도 (중요도: 0.0078)
 - 알아서 (중요도: 0.0076)
 - 그런 (중요도: 0.0076)
 - 기분이 (중요도: 0.0075)
 - 시간을 (중요도: 0.0073)

Model Worst Mistakes

모델 오답노트 분석

오답 분석을 통해 찾은 라벨링 규칙 1

돈이 목적이더라도 ‘신체 훼손/생명 위협’이 섞이면 → 무조건 협박(0)

	정답	예측
김사장. 우리 그동안의 세월을 봐서 내가 많이 봐줬다. 한번만 더 시간을 주면 안되겠나? 김사장도 양심도 없지. 내가 땅파서 장사하나? 하지만 이자가 터무니 없이 비싸네. 그럼 빌리지 말든가 급할때는 좋다고 빌려가놓고 왜그래? 그래서 시간을 조금만 더 주게 제발 이틀 줄게 그안에 안가져오면 눈 한쪽 내놓을 생각해 눈.눈을 말인가? 왜 싫으면 지금 당장 돈 가져오든가 내 어찌든 마련해보겠네.	협박(0)	갈취(1)
형씨 오늘까지 돈 주기로 했잖아 아 그게 뭐하는거야? 약속 안지키는 거 아니지? 아니 하루만 뒤로 미룰 수 없을까요.? 자기야 우리 오늘까지 안주면 어떻게 하기로 했지? 장기 그래!! 그러니까 좋은 말로할때 가져와라 정말 하루뒤면 가져올 수 있어요 하루만 정말 나 화나게 할꺼야? 지금 당장이라도 장기 하나하나 다 떼줘? 아니아닙니다.어떻게든 구해서 오늘 안으로 드릴게요	협박(0)	갈취(1)
빌린 돈 당장 갚아 지금 당장은 돈이 없습니다 내일까지 계좌로 오백 보내. 당장 내일까지요? 그 돈을 어디서 구해요 안 보내면 시간을 조금만 더 주세요 제가 다음 주까지는 꼭 꼭 구해올게요 . 안 보내면 너 콩팥 한 쪽은 무사하지 못할 줄 알아 제발 한번만 봐주세요 죽기 싫으면 내일 저기 앞 뒷골목에서 보자. 흐읍흐읍 넵	협박(0)	갈취(1)

오답 분석을 통해 찾은 라벨링 규칙 2

사진/영상 유포 협박은 목적에 따라 갈린다 → 갈취(1) vs. 기타괴롭힘(3)

	정답	예측
너 나랑 헤어질꺼야? 응 나 이제 너랑 못 만나 나 너 동영상 가지고 있어. 알아? 너 이런 동영상 언제 찍었어? 너 이 영상 학교에 퍼져도 괜찮겠어? 학교 다닐 수 있겠어? . 너 이러는 거 범죄야. 얼른 지워줘. 싫어 너가 나 다시 만난다해주면 지울게 알겠으니 까 얼른 지워줘 하는 거 보고 지울게 보채지마. 너.	갈취(1)	기타괴롭힘(3)
자꾸 이렇게 집착해서 전화자꾸하지마 한번만 만날수 없니 딱 한번만 우린 헤어졌는데 뭘 만나 난 아직 아니야 널 사랑해 뭘 사랑해 그런놈이 둘째를 가지냐 그건 나도 술마시고 술김에 모르고 넌 날 그양 즐기는 상대로 만난거니 이제 끝내자 아니야 조금만 기다려주면 이혼하고 정리될거야 그럼 다른사람 찾아봐 난 아니니 한번만 만나줘 내가 설명할게 너 자꾸 이럼 임신한 니 와이프에게 우리 사진보낸다 야 그렇게하면 나도 가만안있어 니 남자친구랑 집에 나도 폭로해버릴거야 그래 이제야 본심 나오네 넌 그런 양아치야 넌 깨끗한줄 아나보네 그래 우리 서로 다밝히고 깨끗히 서로 다시 시작하자 뭘 시작해 양아치야 너 한 번만 더 전화하고 찾아오면 널 아는 모든사람이 니가 이런사람이라는걸 알게 해줄게	기타괴롭힘(3)	협박(0)
너 나랑 헤어지면 이거 니 주변 사람들에게 다 돌린다 이게 뭐야? 이게 뭐긴 우리 사랑의 증거지 이런걸 언제 찍은거야? 그게 중요해? 동의 없이 찍으면 범죄야 왜 그래 우리 좋았던 시간을 남긴건데 이러지말자 우리 깨끗하게 정리하자 나는 깨끗하게 정리가 안되는데 헤어지는 순간 나 이거 너네 부모님 동생 직장 사람들에게 다 뿌릴거야 좋은 구경 시켜주겠네? 제발 그러지 마.	기타괴롭힘(3)	협박(0)

오답 분석을 통해 찾은 라벨링 규칙 3

군대, 학교 등은 직장으로 보지 않는다 → 기타괴롭힘(3)

정답

예측

야 일병 내가 마스크 똑바로 쓰라했지 죄송합니다! 똑바로 쓰겠습니다!! 어?? 일병이면 소리가 2칸이여야지 소리가 크네 네. 시정하겠습니다 일병이 목소리가 작네 안되겠다 너 맞선임 누구냐 상병님 입니다! 오랜만에 상병 얼차려나 줘야겠네 너때문에 제발 그것만은. 그럼 니가 똑바로 하든가 죄송합니다.	기타괴롭힘(3)	직장내괴롭힘(2)
야 왕따! 뭐하냐 오늘 머리는 감고왔냐? 또 왜그래. 학폭위 한번으로는 모자르디? 이새끼가! 너 죽고싶어 환장했냐? 야 냅뒤냅 뒤. 또 건드려봤자 좋을거 없어 니 친구는 잘아네. 나 건드려봤자 좋을거 없으니 갈길가라. 아오 진짜. 너 오늘 집에가는길 조심 해라. 걱정마. 너같은 새끼 때문에 엄마가 데리러 오실거다. 이 새끼가 지금 장난하나. 확! 야 참아참아. 가자. 애랑 얹혀서 좋을 거 없어.	기타괴롭힘(3)	협박(0)

오답 분석을 통해 찾은 라벨링 규칙 4

진상 손님/민원인의 갑질은 기본적으로 기타 괴롭힘(3) / 구체적인 ‘영업 방해’ 선언 시 → 협박(0)

	정답	예측
아 아저씨 사람을 쳤으면 사과를해야지 아이고 죄송합니다 뭐야 장님이잖아? 죄송합니다 제가 앞이잘안보여서 아니 장님이면 집에 짱박혀있던가 왜 싸돌아다녀? 죄송합니다 에휴 세금 먹고사는 식충들 찻잔 말씀이 너무 심하시네요 내가 내는 세금이 아깝다 .	기타괴롭힘(3)	직장내괴롭힘(2)
학부모님 안녕하세요. 선생님. 우리 애 성적이 왜 이래요? 개똥이가 이번에 성적이 많이 떨어졌죠? 저도 안타깝네요 그러니까 성적이 왜 저러냐구요. 비싼 돈 가져다 줬더니 이게 뭐예요? 지금 장난해요? 개똥이가 똑똑하긴한데 수업에 집중을 안해요. 학원도 자주 안나오고요 그건 너네 핑계고. 우린 돈 못내겠으니. 지난달 학원비 100만원 돌려주세요. 그건 좀. 지금 당장 가져와. 실력도 쥐뿔도 없으면서. 가져오라고. 좀 진정하시죠 야! 지금 당장 가져와. 학부모회랑 커뮤니티에 다 소문내버리기 전에	기타괴롭힘(3)	갈취(1)
이봐요 아가씨 이렇게 해도 되는거야? 손님 죄송합니다 내가 여기 단골이야 사장님 어디있어? 손님 이건 본사 지침이라 어쩔 수가 없어요 됐고 당장 불러와 사장 연락해드리겠습니다 여기 단골인데 이거 하나 못해줘? 진짜 어이가 없어서. 죄송합니다 내가 말만 하면 이 가게 다신 못 열어. 죄송합니다	협박(0)	기타괴롭힘(3)

4가지 규칙에 따라 데이터 증강

- [Rule 1] 돈+상해 → 협박(0) 수정 건수: 29건
- [Rule 2] 유포협박+이득요구 → 갈취(1) 수정 건수: 8건
- [Rule 3] 군대/학교 → 기타괴롭힘(3) 수정 건수: 11건
- [Rule 4] 영업방해 선언 → 협박(0) 수정 건수: 3건

submission score: 0.81



submission score: 0.80

Epoch	Training Loss	Validation Loss	Accuracy	F1 Macro
1	1.411857	1.009317	0.745419	0.716243
2	0.616810	0.497309	0.894889	0.885891
3	0.429906	0.366088	0.908390	0.900853
4	0.297031	0.323436	0.911283	0.904267
5	0.255165	0.319507	0.914176	0.907267

	precision	recall	f1-score	support
협박 대화	0.85	0.90	0.87	185
갈취 대화	0.86	0.86	0.86	190
직장 내 괴롭힘 대화	0.93	0.96	0.94	192
기타 괴롭힘 대화	0.90	0.82	0.86	202
일반 대화	1.00	1.00	1.00	268
accuracy			0.91	1037
macro avg	0.91	0.91	0.91	1037
weighted avg	0.91	0.91	0.91	1037

그 외. 이상한 라벨링들

	정답	예측
어이 코털 왜 왜? 아놔됐고 너 매점가서 곰보빵 두개에 콜라하나 사와라 나 돈없어 돈없어? 그럼 내가 돈줄께 어 여기 1000원 줄테니까 빵두개 콜라하나 사고 거스름돈 거슬러와라 야 택도없어 야 뒤질래? 싸벼서라도 갖고와 색키야 야	기타괴롭힘(3)	갈취(1)
우와 00아 너 이번에 올라온 사진 정말 예쁘더라. 아 응 고마워! 그래서 그 사진 보고 너가 입은 옷이랑 립스틱 따라 사고 싶은 데 어디 제품인지 알려줄 수 있을까 ? 나 정말 너 좋아해서 따라하고 사진 찍고 싶어. 어. 0000 여기 제품이야. 우와 봤는데 너무 비싼 것 같아. 어차피 사진 한 번만 찍을 건데 둘 다 빌려주면 안될까? 아 그래. 빌려줄게. 그러면 빌려주는 김에 전전 피드에 올 린 옷도 같이 빌려줘! 아 그거는 내가 사촌언니 이미 빌려줘서 못 빌려줄 것 같아. 그래? 근데 나 진짜 너무 궁금한데 언니한테 얼른 다시 받아서 빌려주면 안될까? 너 엄청 착하잖아. 믿어도 되는거지?! 알겠어.	기타괴롭힘(3)	갈취(1)
너희부모님 장애인이라며? 넌 왜이렇게 멀쩡하냐? 무슨근거로 그런말을 해? 소문이 그래 너도 부모님처럼 장애인 만들어줘? 시킨일 다했자나 왜그러는거야 그냥 너가 마음에 안들어 그만 괴롭히면 안될까? 안돼 내 스트레스가 풀릴때까지 계속이야 신 고할거야 신고해봐 어디! 내가 너 가만히 안돌테니 언젠가 내가 가만히 안뒤	기타괴롭힘(3)	협박(0)

Hyperparameters

하이퍼파라미터 조정

Seed: 42 / 2024 / 777 → 3개 모델 앙상블



submission score: 0.81



submission score: 0.79

		seed: 42			seed: 2024			seed: 777		
Epoch	Training Loss	Validation Loss	Accuracy	F1 Macro	Validation Loss	Accuracy	F1 Macro	Validation Loss	Accuracy	F1 Macro
1	No log	1.015757	0.788814	0.767269	0.986892	0.796528	0.768986	1.035995	0.631630	0.546720
2	No log	0.487250	0.906461	0.898566	0.455333	0.899711	0.892710	0.516067	0.895853	0.886297
3	No log	0.357204	0.911283	0.903848	0.336014	0.910318	0.903049	0.360980	0.905497	0.897463
4	0.763189	0.316365	0.917068	0.910653	0.297975	0.918033	0.911623	0.328595	0.909354	0.901838
5	0.763189	0.311426	0.916104	0.909464	0.295197	0.913211	0.906082	0.324793	0.910318	0.902910

Hyperparameter 조정

MAX_LENGTH	BATCH_SIZE	LEARNING_RATE	OPTIMIZER	SCHEDULER	EPOCHS	Weight Decay	Epsilon	Max Grad Norm	SEED
128	32	1 e-5	AdamW	Linear Warmup	5	0.01(default)	1 e-5	1	42

submission score: 0.81

▼ Learnig rate 1e-5 → 2e-5 + Weight Decay 수정



MAX_LENGTH	BATCH_SIZE	LEARNING_RATE	OPTIMIZER	SCHEDULER	EPOCHS	Weight Decay	Epsilon	Max Grad Norm	SEED
128	32	2 e-5	AdamW	Linear Warmup	5	0.01(adjusted)	1 e-5	1	42

submission score: 0.82

▼ Max length 128 → 256



MAX_LENGTH	BATCH_SIZE	LEARNING_RATE	OPTIMIZER	SCHEDULER	EPOCHS	Weight Decay	Epsilon	Max Grad Norm	SEED
256	32	2 e-5	AdamW	Linear Warmup	5	0.01(adjusted)	1 e-5	1	42


submission score: 0.83

CONCLUSION

결론

최종 결론

과제는 공격 단어 탐지가 아닌, 대화 포맷/화자 전환/문맥 흐름/데이터 분포를 학습하는 문제



실험 단계	확인한 현상	Submission	결론
모델 선정	KcELECTRA가 가장 높은 실제 제출 점수	0.77	모델 크기보다 DKTC 데이터와의 도메인 적합성이 중요
증강 실험	Local F1은 상승했지만 제출 점수는 하락/정체	0.72~0.74	무작위/취약 패턴 증강만으로는 일반화 성능 확보가 어려움
적대적 검증	전체 분포는 유사, 일반대화만 AUC 0.9495	-	핵심 문제는 위협 클래스보다 일반대화 분포 차이
분포 보정	2-way HN·Other Theme 추가 후 점수 상승	0.78 → 0.81	평가 분포에 가까운 일반대화를 설계할수록 성능 개선
최종 조정	LR, Weight Decay, Max Length 조정	0.83	대화 전체 문맥을 더 잘 반영하도록 최적화

Task-Adaptive Pretraining (TAPT/DAPT)

Gururangan et al., ACL 2020

이미 사전학습된 LM도 target domain/task에 가까운 데이터로 한 번 더 pretraining하면 성능이 향상될 수 있음




Figure 1. task는 target domain 안에서 더 좁고 특수한 분포

Domain	Task	RoBERTa	Additional Pretraining Phases		
			DAPT	TAPT	DAPT + TAPT
BIOMED	CHEMPROT	81.9 _{1.0}	84.2 _{0.2}	82.6 _{0.4}	84.4 _{0.4}
	†RCT	87.2 _{0.1}	87.6 _{0.1}	87.7 _{0.1}	87.8 _{0.1}
CS	ACL-ARC	63.0 _{5.8}	75.4 _{2.5}	67.4 _{1.8}	75.6 _{3.8}
	SciERC	77.3 _{1.9}	80.8 _{1.5}	79.3 _{1.5}	81.3 _{1.8}
NEWS	HYPERPARTISAN	86.6 _{0.9}	88.2 _{5.9}	90.4 _{5.2}	90.0 _{6.6}
	†AGNEWS	93.9 _{0.2}	93.9 _{0.2}	94.5 _{0.1}	94.6 _{0.1}
REVIEWS	†HELPFULNESS	65.1 _{3.4}	66.5 _{1.4}	68.5 _{1.9}	68.7 _{1.8}
	†IMDB	95.0 _{0.2}	95.4 _{0.1}	95.5 _{0.1}	95.6 _{0.1}

Table 5. RoBERTa 대비 DAPT / TAPT / DAPT+TAPT 성능 향상



4개 도메인·8개 classification task에서 adaptive pretraining의 효과를 확인

우리 실험에 연결 - TAPT로 기대할 수 있는 향상 지점

“일반대화 분포를 맞췄더니 점수가 올랐다 → 모델도 DKTC식 대화 분포를 먼저 학습시키자”

추후 실험 흐름



우리 실험에서 확인한 문제	TAPT로 보완할 부분	향상 기대 지점
일반대화만 train-test 분포 차이 큼 (AUC 0.9495)	DKTC식 화자 전환, 구어체, 음성 기반 노이즈, 대화 길이 분포를 라벨 학습 전 먼저 흡수	일반대화 false positive 감소
비속어·과격 표현이 일반대화에도 등장 → trigger word 편향	표면 단어가 아니라 앞뒤 반응과 대화 흐름을 사전학습 단계에서 익힘	일반대화 vs 위협성 대화 경계 강화
2-way HN·Other Theme 추가 시 0.78 → 0.81로 상승	추가 데이터 생성이 아니라 모델 자체를 task distribution에 적응	분포 보정 효과를 모델 학습 단계로 확장
Max Length 256 확장 후 개선	긴 2-way 대화의 후반 맥락까지 더 안정적으로 반영	문맥 기반 판단 성능 향상

Reference

1. Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don't Stop Pretraining: Adapt Language Models to Domains and Tasks. ACL 2020.
2. Tunib AI. DKTC: Korean Threatening Conversation Dataset. Lee, H. et al.
3. KLUE: Korean Language Understanding Evaluation. NeurIPS 2021. Lee, J.

Any Questions?
